

TRABALHO FINAL

Prof. Filipe Braida

Introdução à Teoria de Sistemas de Recomendação

1 Cenário

Atualmente, há um crescimento exponencial no número de usuários que utilizam sistemas de comércio eletrônico. Esses sites oferecem uma vasta gama de produtos e serviços, o que pode sobrecarregar os consumidores em suas decisões de compra ou consumo. Os Sistemas de Recomendação (SR) têm desempenhado um papel importante ao auxiliar os usuários a encontrar produtos e serviços relevantes [1].

Grande parte das pesquisas em SR se concentra na melhoria dos algoritmos de previsão para aprimorar a acurácia [3]. A competição *Netflix Prize* demonstrou que havia muitas oportunidades para melhorar significativamente a acurácia dos algoritmos [2]. Desde então, surgiram pesquisas focadas em problemas como a esparsidade dos dados e a personalização das recomendações, que influenciam diretamente o desempenho dos recomendadores.

2 Objetivo do Trabalho

O objetivo deste trabalho é implementar e comparar diferentes algoritmos de filtragem colaborativa, incluindo abordagens baseadas em memória e baseadas em modelo. Também será explorada a questão da hiperparametrização, com o ajuste de parâmetros para otimizar o desempenho dos algoritmos, além da escolha e aplicação de uma metodologia apropriada para avaliação. A base de dados utilizada será a MovieLens 100k, podendo ser complementada por outras bases para fins comparativos.

3 Especificações

A seguir, são apresentadas as especificações que orientarão o desenvolvimento e a avaliação deste trabalho:

- **Escolha e Implementação de Algoritmos:**

- Implementar ao menos um algoritmo de filtragem colaborativa baseado em memória, *e.g.*, user-based.
- Implementar ao menos um algoritmo de filtragem colaborativa baseado em modelo, *e.g.*, Regularized SVD.
- Opcionalmente, incluir outros algoritmos com o objetivo de ampliar o escopo da comparação.

- **Hiperparametrização:**

- Investigar e ajustar os hiperparâmetros de cada algoritmo para aprimorar seu desempenho.
- Aplicar técnicas de validação para garantir a robustez dos modelos.

- **Metodologia de Avaliação:**

- Avaliar a qualidade da previsão das notas atribuídas aos itens, utilizando métricas adequadas.
- Opcionalmente, realizar uma avaliação da qualidade da recomendação.
- As métricas escolhidas devem ser devidamente justificadas, de acordo com os objetivos da avaliação realizada.

- **Base de Dados:**

- Utilizar a base MovieLens 100k para o treinamento e a avaliação dos modelos.
- Opcionalmente, empregar outras bases de dados para uma análise mais abrangente e generalizável.

4 Estrutura do Relatório

Ao final, o grupo deverá entregar um relatório apresentando a metodologia de avaliação adotada e os resultados obtidos. O relatório deverá conter as seguintes seções:

- **Introdução:** Apresentação geral do trabalho, incluindo o cenário, os objetivos e a motivação da proposta.
- **Experimentos:** Descrição das bases de dados utilizadas, detalhamento da metodologia aplicada, dos algoritmos implementados e análise dos resultados obtidos.
- **Conclusão:** Síntese dos principais achados, considerações sobre o desempenho dos algoritmos avaliados e sugestões para trabalhos futuros.

5 Possíveis Extras

Para enriquecer ainda mais o trabalho e proporcionar uma análise mais abrangente, os alunos podem considerar a implementação dos seguintes recursos adicionais:

- **Uso de Outras Bases de Dados:** Além da MovieLens 100k, podem ser utilizadas outras bases, como MovieLens 1M, CiaoDVD ou Last.fm, a fim de avaliar a robustez dos algoritmos em diferentes contextos e volumes de dados.
- **Utilização de Outros Algoritmos:** Desenvolver e testar algoritmos adicionais ou variações dos utilizados. Isso pode incluir tanto implementações próprias quanto o uso de bibliotecas externas. É importante deixar claro no relatório quais algoritmos foram implementados diretamente e quais foram utilizados por meio de bibliotecas.
- **Análise de Sensibilidade:** Investigar como a variação de diferentes parâmetros — como o tamanho do conjunto de treinamento, o número de vizinhos ou a quantidade de fatores latentes — impacta o desempenho dos algoritmos.

- **Visualização de Resultados:** Produzir visualizações avançadas, como gráficos de dispersão, curvas ROC ou matrizes de confusão, com o objetivo de facilitar a compreensão comparativa dos desempenhos.
- **Implementação de Técnicas de Preprocessamento:** Explorar e aplicar técnicas de pré-processamento de dados, como normalização ou remoção de outliers, a fim de avaliar o impacto dessas abordagens na acurácia e eficiência dos modelos.
- **Benchmarking em Diferentes Cenários:** Avaliar o desempenho dos algoritmos em cenários distintos, como recomendações de novos lançamentos versus itens populares, de modo a investigar sua adaptabilidade e flexibilidade.

6 Regras para Condução do Trabalho

A seguir, apresentam-se as regras que deverão ser observadas na realização do trabalho:

- O trabalho poderá ser realizado individualmente ou em duplas.
- É obrigatório utilizar, no mínimo, um algoritmo baseado em memória e um baseado em modelo.
- Deve-se realizar a avaliação de, pelo menos, um hiperparâmetro para cada modelo implementado.
- A metodologia de avaliação adotada deverá ser adequada aos objetivos propostos, com uso de métricas apropriadas.
- O relatório deverá ser elaborado utilizando o template da ACM, disponível em: [ACM Template](#).
- Cada aluno deverá submeter o PDF final do relatório por meio da plataforma Moodle.

References

- [1] G. Adomavicius and A. Tuzhilin. Toward the next generation of recommender systems: a survey of the state-of-the-art and possible extensions. *IEEE Transactions on Knowledge and Data Engineering*, 17(6):734–749, jun 2005. ISSN 1041-4347. doi: 10.1109/TKDE.2005.99.
- [2] Yehuda Koren, Robert Bell, and Chris Volinsky. Matrix factorization techniques for recommender systems. *Computer*, 42(8):30–37, 2009. URL http://ieeexplore.ieee.org/xpls/abs/_all.jsp?arnumber=5197422.
- [3] Francesco Ricci, Lior Rokach, Bracha Shapira, and Paul B Kantor. Recommender Systems Handbook. *Media*, 2011. doi: 10.1007/978-0-387-85820-3. URL <http://www.springerlink.com/index/10.1007/978-0-387-85820-3>.